

De los datos a la decisión inteligente

Aplicaciones de Machine Learning, Data Mining e IA.

Ignacio Sánchez-Gendríz



MINISTÉRIO DA
CIÊNCIA, TECNOLOGIA
E INOVAÇÃO



May 6, 2026



Presentación institucional

Ignacio Sánchez Gendriz — CETENE / MCTI



Ignacio Sánchez Gendriz

Investigador — CETENE / MCTI



Ciencia de Datos • Inteligencia Artificial •
Machine Learning • DSP • Computación Aplicada



Aplicaciones en monitoreo ambiental, bioacústica,
geociencias y sistemas inteligentes.



ignacio.gendriz@cetene.gov.br



CETENE

Centro de Tecnologias Estratégicas do Nordeste

Unidad de investigación del Ministério da Ciência, Tecnologia e Inovação (MCTI), Brasil



Misión:

Desarrollar tecnologías sostenibles orientadas al desarrollo socioeconómico del Nordeste de Brasil.



Áreas estratégicas:


Nanotecnologías • Biotecnologías • Computación aplicada

Contenido

- 1 Contexto y problema
- 2 Análisis Exploratorio de Datos
- 3 Representación y modelado
- 4 Evaluación e interpretación

Motivación y pregunta central

- La ingeniería moderna genera datos a partir de ensayos, sensores, inspecciones, simulaciones y registros operacionales.
- El valor técnico aparece cuando esos datos son organizados, analizados e interpretados.
- Data Mining y Machine Learning permiten convertir datos en información útil para apoyar decisiones de ingeniería.
- En este estudio de caso, la pregunta central es:
- **¿Cómo transformar datos experimentales de mezclas de concreto en información útil para estimar su resistencia y apoyar decisiones técnicas?**



Problema de ingeniería: resistencia del concreto

- La resistencia a la compresión es una propiedad fundamental para evaluar el desempeño del concreto.
- Depende de la composición de la mezcla, los materiales cementicios, la cantidad de agua, los agregados, los aditivos y la edad de curado.
- La relación entre estos factores y la resistencia final puede ser no lineal.
- Por ello, el problema permite integrar conocimiento de ingeniería, análisis de datos y modelos predictivos.
- El objetivo no es solo predecir un valor, sino comprender el proceso que lleva de los datos a una decisión informada.




Base de datos y formulación predictiva

- Se utilizó el dataset *Concrete Compressive Strength*, disponible en el repositorio UCI.
- La base contiene datos experimentales de mezclas de concreto:
 - 1030 observaciones;
 - 8 variables de entrada;
 - 1 variable objetivo;
 - datos tabulares y cuantitativos.
- Variables de entrada: cemento, escoria, ceniza volante, agua, superplastificante, agregado grueso, agregado fino y edad.
- Variable objetivo: **resistencia a la compresión del concreto**, medida en MPa.
- Desde Machine Learning, el problema se formula como una tarea de **regresión supervisada**.



Pipeline general del análisis

- El análisis sigue un flujo completo, desde los datos hasta la interpretación.
- Etapas principales:
 - comprensión del problema;
 - Análisis Exploratorio de Datos (*EDA*);
 - preprocesamiento;
 - ingeniería de características;
 - modelado y evaluación;
 - interpretación de resultados.
- El objetivo es apoyar una decisión técnica, no solo entrenar un modelo.



Exploración inicial de los datos

- La exploración inicial permite verificar la estructura y calidad del dataset.
- Se analizaron:
 - número de muestras y variables;
 - tipos de datos;
 - unidades físicas;
 - valores mínimos y máximos;
 - presencia de valores ausentes.


6 Exploración inicial



- ✓ Calidad de datos
- ✓ Valores faltantes = 0
- ✓ Rangos válidos
- ✓ Vista general del conjunto de datos


Distribuciones, correlaciones y primeros patrones

- El EDA permite identificar patrones antes del modelado.
- Algunas variables presentan muchos valores cercanos a cero, como escoria, ceniza volante y superplastificante.
- La correlación inicial sugiere relaciones relevantes entre resistencia, cemento, edad, agua y superplastificante.
- Estos resultados orientan la representación de los datos y la selección de modelos.



Preparación para el modelado

- Los datos fueron separados en tres conjuntos:
 - entrenamiento: ajuste de los modelos;
 - validación: comparación y selección;
 - prueba: evaluación final.
- Las variables fueron estandarizadas con **StandardScaler**.
- La separación evita evaluar el modelo con datos usados durante el entrenamiento.
- La evaluación final simula el desempeño esperado en datos nuevos.




Representación e ingeniería de características

- La representación de los datos influye directamente en el desempeño del modelo.
- Se incorporó conocimiento físico mediante variables derivadas:
 - relación agua/cemento;
 - material cementicio total;
 - relación agua/material;
 - proporción de escoria y ceniza volante;
 - relación de superplastificante.
- PCA se utilizó como herramienta exploratoria para visualizar la estructura global de los datos.



Comparación inicial de modelos

- Se evaluaron modelos con diferentes niveles de complejidad:
 - Regresión Lineal;
 - Árbol de Decisión;
 - Random Forest;
 - Gradient Boosting;
 - MLP Regressor.
- La comparación se realizó usando variables originales y variables derivadas.
- El objetivo fue identificar el modelo con mejor capacidad predictiva inicial.



Random Forest como modelo principal

- Random Forest obtuvo el mejor desempeño en validación.
- Resultados principales:
 - variables originales: $R^2 \approx 0.913$;
 - variables derivadas: $R^2 \approx 0.926$.
- Las variables derivadas mejoraron el desempeño predictivo.
- El modelo fue seleccionado para comparar diferentes representaciones de los datos.




Evaluación final de las representaciones

- Se compararon cuatro representaciones con Random Forest:
 - variables originales;
 - variables derivadas;
 - originales + derivadas;
 - variables preseleccionadas.
- Mejor desempeño en prueba:
 - $R^2 = 0.8991$;
 - RMSE = 5.4232 MPa;
 - MAE = 3.7260 MPa.
- Las variables preseleccionadas ofrecieron el mejor equilibrio entre precisión y simplicidad.



Interpretación del modelo

- La interpretación permite entender qué variables guían las predicciones.
- Factores más relevantes en el modelo final:
 - relación agua/material;
 - edad;
 - material cementicio total;
 - relación agua/cemento;
 - cemento.
- Los resultados son coherentes con el conocimiento físico del problema.
- Interpretar el modelo ayuda a transformar predicciones en información útil para la decisión técnica.



Del análisis al desarrollo de una solución computacional

- El notebook puede evolucionar hacia una solución computacional reproducible.
- Posibles extensiones:
 - automatización del pipeline;
 - validación cruzada y ajuste de hiperparámetros;
 - interfaz web para predicción;
 - API para integración con otros sistemas;
 - dashboard para apoyo a decisiones.
- La conexión entre modelo, interfaz y usuario convierte el análisis en una herramienta práctica.



Mensajes finales y transición al notebook

- Un proyecto de Machine Learning aplicado depende de todo el flujo de análisis.
- El EDA permite comprender los datos antes del modelado.
- Las variables derivadas incorporan conocimiento de ingeniería.
- Random Forest capturó adecuadamente relaciones no lineales.
- La interpretación conecta el modelo con la toma de decisiones.
- A continuación, el **notebook**^a muestra la implementación práctica del flujo completo.



^a<https://github.com/igendrizz/de-datos-a-decision-inteligente-ml-ia>

Agradecimientos

Especialmente

Por la invitación, la articulación para la realización de esta presentación.



Prof. Dr. Alexander Alvarez Rosario

Profesor Titular – Ingeniería de Sistemas



Organizadores del evento

A los organizadores de la **IX Semana Internacional de Ingeniería**, por el espacio de intercambio académico y profesional.